

# Лабораторная работа 10

## Наивный Байесовский классификатор

Гузовская Александра Чеславовна  
Б9123-01.03.02сп

9 июня 2025 г.

### Матчасть

Наивный Байесовский классификатор основан на теореме Байеса со строгим (наивным) предположением о независимости признаков между собой при заданном классе.

Для объекта с признаками  $x = (x_1, x_2, \dots, x_m)$  вероятность принадлежности к классу  $y_k$  вычисляется как:

$$P(y_k|x) = P(y_k) \cdot \prod \frac{P(x_i|y_k)}{P(x)}$$

где:

- >  $P(y_k)$  — априорная вероятность класса  $y_k$
- >  $P(x_i|y_k)$  — вероятность признака  $x_i$  для класса  $y_k$
- >  $P(x)$  — нормирующая константа

Для дискретных признаков  $P(x_i|y_k)$  оценивается относительной частотой с добавлением сглаживания Лапласа:

$$P(x_i|y_k) = \frac{(N(x_i, y_k) + \alpha)}{(N(y_k) + \alpha \cdot n_i)}$$

где:

- >  $\alpha = 1$  (параметр сглаживания)
- >  $n_i$  — количество уникальных значений признака

Для непрерывных признаков предполагается нормальное распределение:

$$P(x_i|y_k) = \left( \frac{1}{2\pi\sigma^2} \right) \cdot \exp \left( -(x - \mu)^2 / (2\sigma^2) \right)$$

где:

- >  $\mu$  — среднее признака для класса  $y_k$
- >  $\sigma$  — стандартное отклонение признака для класса  $y_k$

## Код программы

```
import numpy as np
import scipy.stats as sps
from sklearn.metrics import accuracy_score
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB, MultinomialNB
from sklearn.datasets import load_iris, fetch_openml
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import OrdinalEncoder

class NaiveBayes:
    def __init__(self, discrete_flags):
        """
        Конструктор
        принимает список флагов (True/False) для каждого признака,
        указывает, является ли признак дискретным
        """
        self.discrete_flags = discrete_flags
        self.class_probs = None
        self.feature_params = None
        self.classes = None

    def fit(self, X, y):
        """Обучение модели на тренировочных данных"""
        self.classes = np.unique(y)
        n_features = X.shape[1]

        self.class_probs = {c: np.mean(y == c) for c in self.classes}

        self.feature_params = {}

        for feature_idx in range(n_features):
            self.feature_params[feature_idx] = {}
```

```

for c in self.classes:
    feature_values = X[y == c, feature_idx]

    if self.discrete_flags[feature_idx]:
        unique, counts = np.unique(feature_values,
                                    return_counts=True)
        total = len(feature_values)
        n_unique = len(unique)

        # Сглаживание Лапласа
        probs = {val: (cnt + 1)/(total + n_unique)
                  for val, cnt in zip(unique, counts)}
        default_prob = 1/(total + n_unique)

        self.feature_params[feature_idx][c] = {
            'type': 'discrete',
            'probs': probs,
            'default_prob': default_prob
        }
    else:
        mean = np.mean(feature_values)
        std = np.std(feature_values)
        if std == 0: std = 1e-9

        self.feature_params[feature_idx][c] = {
            'type': 'continuous',
            'mean': mean,
            'std': std
        }

def predict(self, X):
    """Предсказание классов для новых данных"""
    predictions = []

    for obj in X:
        max_log_prob = -np.inf
        best_class = None

        for c in self.classes:
            log_prob = np.log(self.class_probs[c])

```

```

        for feature_idx in range(len(obj)):
            params = self.feature_params[feature_idx][c]
            val = obj[feature_idx]

            if params['type'] == 'discrete':
                if val in params['probs']:
                    log_prob += np.log(params['probs'][val])
                else:
                    log_prob += np.log(params['default_prob'])
            else:
                log_prob += sps.norm.logpdf(val, loc=params['mean'], sca

        if log_prob > max_log_prob:
            max_log_prob = log_prob
            best_class = c

    predictions.append(best_class)

    return np.array(predictions)

def test_iris():
    """Тестирование на непрерывных данных (ирисы Фишера)"""
    iris = load_iris()
    X = iris.data
    y = iris.target

    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=1/3, random_state=42)

    nb = NaiveBayes(discrete_flags=[False]*4)
    nb.fit(X_train, y_train)
    y_pred = nb.predict(X_test)

    accuracy = accuracy_score(y_test, y_pred)
    print(f"\nТестирование на Iris (непрерывные признаки):")
    print(f"Наивный Байес (реализация): {accuracy:.2f}")

    gnb = GaussianNB()
    gnb.fit(X_train, y_train)
    y_pred_sk = gnb.predict(X_test)

```

```

accuracy_sk = accuracy_score(y_test, y_pred_sk)
print(f"GaussianNB (sklearn): {accuracy_sk:.2f}")

def test_zoo():
    """Тестирование на дискретных данных (датасет Zoo)"""
    zoo = fetch_openml(name='zoo', version=1)
    X = zoo.data
    y = zoo.target

    encoder = OrdinalEncoder()
    X_encoded = encoder.fit_transform(X).astype(int)

    le = LabelEncoder()
    y_encoded = le.fit_transform(y)

    X_train, X_test, y_train, y_test = train_test_split(
        X_encoded, y_encoded, test_size=1/3, random_state=42)

    nb = NaiveBayes(discrete_flags=[True]*X_encoded.shape[1])
    nb.fit(X_train, y_train)
    y_pred = nb.predict(X_test)

    accuracy = accuracy_score(y_test, y_pred)
    print(f"\nТестирование на Zoo (дискретные признаки):")
    print(f"Наивный Байес (реализация): {accuracy:.2f}")

    mnb = MultinomialNB()
    mnb.fit(X_train, y_train)
    y_pred_sk = mnb.predict(X_test)
    accuracy_sk = accuracy_score(y_test, y_pred_sk)
    print(f"MultinomialNB (sklearn): {accuracy_sk:.2f}")

if __name__ == "__main__":
    test_iris()
    test_zoo()

```

## Вывод программы

Для непрерывных данных на примере "ирисов Фишера"

```
Тестирование на Iris (непрерывные признаки):  
Наивный Байес (реализация): 0.96  
GaussianNB (sklearn): 0.96
```

Для дискретных данных на примере "зоопарка"

```
Тестирование на Zoo (дискретные признаки):  
Наивный Байес (реализация): 0.88  
MultinomialNB (sklearn): 0.88
```